

Reproduction Operator Sensitivity in MOEA/D under Tchebycheff Decomposition: An Empirical Study on Regular and Irregular Pareto Fronts

Isabela Medeiros Belo Lopes¹, Lucas Rodolfo Celestino Farias²

¹Universidade Católica de Pernambuco (UNICAP)
Recife – PE – Brazil

²CESAR School
Recife – PE – Brazil

lrcf@cesar.school

Abstract. *This paper presents a controlled empirical study on the sensitivity of MOEA/D to reproduction operators under fixed Tchebycheff decomposition. Eight operator variants were evaluated in PlatEMO 4.15 on DTLZ and IDTLZ benchmark instances with regular and irregular Pareto fronts, two to five objectives, and different decision-space dimensions. The study does not propose a new algorithm; instead, it isolates the effect of replacing the reproduction mechanism while preserving the same decomposition scheme. Each configuration was executed 30 times independently and compared with the baseline MOEA/D using IGD and a Wilcoxon test. The evidence indicates scenario-dependent behavior: ABC and simulated annealing show the strongest aggregated profile on regular many-objective fronts (9 wins, 4 losses, 3 ties each; IGD ratio $r = 0.90$), MMOPSO achieves the lowest aggregated IGD ratio on irregular fronts ($r = 0.64$ – 0.95) despite limited statistical wins, and NMS degrades performance in nearly every configuration (0–1 wins across all scenario groups). The results support operator selection based on scenario and motivate adaptive mechanisms conditioned on the Pareto-front geometry.*

Resumo. *Este artigo apresenta um estudo empírico controlado sobre a sensibilidade do MOEA/D a operadores de reprodução sob decomposição de Tchebycheff fixa. Oito variantes de operadores foram avaliadas na PlatEMO 4.15 em instâncias DTLZ e IDTLZ com Fronteiras de Pareto regulares e irregulares, dois a cinco objetivos e diferentes dimensões do espaço de decisão. O estudo não propõe um novo algoritmo; em vez disso, isola o efeito da substituição do mecanismo de reprodução mantendo a mesma decomposição. Cada configuração foi executada 30 vezes de forma independente e comparada ao MOEA/D base por IGD e teste de Wilcoxon. As evidências indicam comportamento dependente do cenário: ABC e recozimento simulado apresentam o melhor perfil agregado em frentes regulares com muitos objetivos (9 vitórias, 4 derrotas e 3 empates cada; razão de IGD $r = 0,90$), MMOPSO obtém a menor razão agregada de IGD em frentes irregulares ($r = 0,64$ – $0,95$) apesar de poucas vitórias estatísticas, e NMS degrada o desempenho em quase todas as configurações (0–1 vitórias em todos os grupos de cenário). Os resultados apoiam a escolha de operadores por cenário e motivam mecanismos adaptativos condicionados à geometria da Fronteira de Pareto.*

1. Introdução

Problemas de otimização multiobjetivo envolvem objetivos conflitantes. Em vez de uma única solução ótima, busca-se aproximar um conjunto de soluções não dominadas capaz de representar diferentes compromissos ao longo da Fronteira de Pareto. Entre os algoritmos evolutivos multiobjetivo, o MOEA/D (*Multiobjective Evolutionary Algorithm based on Decomposition*) consolidou-se como uma das principais abordagens baseadas em decomposição, pois transforma um problema multiobjetivo em subproblemas escalares cooperativos associados a vetores de peso [Zhang and Li 2007].

O desempenho do MOEA/D depende de decisões algorítmicas que afetam convergência e diversidade. Duas delas são particularmente relevantes: a função de escalarização, que define como cada subproblema avalia uma solução candidata, e o operador de reprodução, que define como novas soluções são geradas. A literatura apresenta avanços em escalarização, adaptação de pesos, seleção adaptativa de operadores e variantes híbridas do MOEA/D [Li and Zhang 2009, Li et al. 2014, Wang et al. 2015, Wang et al. 2019, Almeida et al. 2018, Li 2024]. Ainda assim, há espaço para evidência empírica controlada sobre o comportamento de diferentes operadores quando a função escalarizante é mantida fixa, principalmente ao comparar Fronteiras de Pareto regulares e irregulares.

Este artigo investiga esse recorte. A contribuição está na análise sistemática do efeito da substituição do mecanismo de reprodução no MOEA/D sob Tchebycheff. Essa escolha diferencia o estudo de abordagens que combinam várias alterações simultâneas, pois permite observar o papel do operador com menor interferência de fatores como escalarização, atualização de subproblemas ou mudança de métrica.

A questão de pesquisa é: *em que medida a escolha do operador de reprodução altera o desempenho do MOEA/D sob escalarização de Tchebycheff em problemas com Fronteiras de Pareto regulares e irregulares?* A hipótese é que não existe um operador universalmente superior; a adequação de cada operador depende da geometria da fronteira, do número de objetivos e da dimensionalidade do espaço de decisão.

As contribuições são quatro. Primeiro, o artigo apresenta uma comparação sistemática de oito variantes de operadores de reprodução no MOEA/D sob protocolo experimental comum. Segundo, organiza a análise por geometria da Fronteira de Pareto, separando instâncias regulares e irregulares. Terceiro, consolida os resultados por configurações únicas, evitando duplicações indevidas nas tabelas originais. Quarto, sintetiza recomendações práticas para configuração do MOEA/D e indica caminhos para seleção adaptativa de operadores.

O restante deste artigo está organizado da seguinte forma. A Seção 2 apresenta os trabalhos relacionados. A Seção 3 apresenta a fundamentação conceitual e delimita o escopo do estudo, incluindo o MOEA/D, a escalarização de Tchebycheff, os operadores avaliados, a métrica IGD e a classificação das Fronteiras de Pareto. A Seção 4 descreve o protocolo experimental, o ambiente de execução, os benchmarks, os parâmetros adotados e o procedimento estatístico. A Seção 5 discute os resultados agregados e detalhados, relacionando o desempenho dos operadores aos diferentes cenários experimentais. Por fim, a Seção 6 apresenta as conclusões, as implicações práticas e as direções para trabalhos futuros.

2. Trabalhos Relacionados

A literatura sobre MOEA/D avança em duas frentes principais a este estudo: adaptação da escalarização e seleção ou adaptação do operador de reprodução. Li e Zhang [Li and Zhang 2009] sugeriram estratégias de atualização de vizinhança e ficou evidente que a escolha do operador de reprodução DE com a mutação polinomial afeta diretamente a capacidade do MOEA/D de lidar com Pareto Sets complicados, porém, levando em consideração um único operador fixo ao longo de toda a execução. Li et al. [Li et al. 2014] introduziram seleção adaptativa de operadores a partir do *bandits* multi-braço, alternando de forma dinâmica entre os operadores durante a fase de busca; Almeida et al. [Almeida et al. 2018] seguem a mesma linha com hiper-heurísticas baseadas em *bandits*. Wang et al. [Wang et al. 2019] propuseram um *framework* de *ensemble* que combina múltiplos operadores de maneira simultânea na população. Esses trabalhos demonstram benefícios ao tornar o operador adaptativo, porém não isolam sistematicamente o efeito de cada operador individualmente sob decomposição fixa, então a adaptação e a comparação ficam confundidas no mesmo experimento.

Do lado da escalarização, Wang et al. [Wang et al. 2015] propuseram funções de escalarização adaptativas, e Li [Li 2024] apresenta uma revisão do MOEA/D, incluindo taxonomias de operadores e escalarizações, mas sem uma comparação empírica controlada de forma específica sobre sensibilidade a operadores em frentes regulares e irregulares.

Os oito operadores de reprodução reproduzidos e avaliados neste artigo têm como base artigos que propuseram, de formas diferentes, mecanismos alternativos para melhorar a busca do MOEA/D: DE segue Li e Zhang [Li and Zhang 2009]; CMA-ES segue Zapotecas-Martínez et al. [Zapotecas-Martínez et al. 2015], que injetam adaptação de covariância e de passo em cada subproblema; a busca simplex de Nelder-Mead acoplada a DE segue Zhang et al. [Zhang et al. 2017]; o recozimento simulado adaptativo segue Li e Landa-Silva [Li and Landa-Silva 2011]; o ACO para problemas combinatórios segue Ke et al. [Ke et al. 2013]; o ABC multi-colônia com arquivo externo segue Zhong et al. [Zhong et al. 2014]; e o PSO com múltiplas estratégias de busca segue Lin et al. [Lin et al. 2015]. Esses artigos serviram de inspiração conceitual para versões simplificadas e adaptadas ao domínio contínuo; os mecanismos originais propõem componentes mais elaborados (múltiplas colônias, matrizes de feromônio discretas, estado persistente entre gerações, esquemas de resfriamento) do que os operadores aqui implementados.

Contudo, a literatura apresenta evidência de que operadores adaptativos e escalarizações adaptativas melhoram o desempenho, mas não isola, sob protocolo comum e decomposição fixa, o efeito de oito famílias de operadores distintas em frentes regulares e irregulares. É essa lacuna que este artigo busca preencher.

3. Fundamentação e Escopo

O MOEA/D decompõe um problema multiobjetivo em N subproblemas escalares. Cada subproblema é associado a um vetor de pesos $\lambda = (\lambda_1, \dots, \lambda_m)^T$, em que m é o número de objetivos, e utiliza vizinhanças de vetores de peso para compartilhar soluções. Considerando x como vetor de decisão, $f(x)$ como vetor objetivo e z^* como ponto ideal estimado, a escalarização de Tchebycheff é definida por

$$g^{te}(x \mid \lambda, z^*) = \max_{1 \leq i \leq m} \{\lambda_i |f_i(x) - z_i^*|\}. \quad (1)$$

Essa formulação é adotada para isolar a influência dos operadores de reprodução. Como Tchebycheff é uma configuração clássica do MOEA/D e lida melhor que a soma ponderada com certas frentes não convexas, ela fornece um ponto de comparação adequado para um estudo de sensibilidade [Zhang and Li 2007, Li and Zhang 2009].

Neste estudo, cada variante é tratada como um mecanismo alternativo de geração de descendentes dentro do ciclo de atualização do MOEA/D. Assim, ABC, ACO, CMA-ES, DE, EDA, MMOPSO, NMS e SA não são avaliados como algoritmos completos independentes, mas como operadores ou módulos de reprodução acoplados ao mesmo arcabouço de decomposição. Eles representam mecanismos distintos de busca: perturbação estocástica, amostragem probabilística, adaptação de distribuição, diferenças vetoriais, enxames e busca local [Karaboga and Basturk 2007, Dorigo et al. 1996, Hansen and Ostermeier 2001, Storn and Price 1997, Zhou et al. 2015, Lin et al. 2015, Nelder and Mead 1965, Kirkpatrick et al. 1983]. Diferenças de desempenho, portanto, podem indicar compatibilidades ou tensões entre dinâmica de reprodução, decomposição e geometria da fronteira.

A métrica principal é a Distância Geracional Invertida (IGD). Dado um conjunto de referência P^* e um conjunto aproximado A , a IGD é dada por

$$IGD(A, P^*) = \frac{1}{|P^*|} \sum_{v \in P^*} d(v, A), \quad (2)$$

em que $d(v, A)$ é a menor distância euclidiana entre v e as soluções em A . Valores menores indicam melhor proximidade e cobertura em relação à fronteira de referência. A IGD foi escolhida por ser amplamente usada em estudos de otimização multi-objetivo e por combinar, em uma única medida, aspectos de convergência e diversidade [Van Veldhuizen and Lamont 1998, Tian et al. 2017]. Sua limitação é não substituir métricas complementares, como Hipervolume, especialmente quando diferentes aproximações apresentam compromissos distintos entre cobertura e proximidade.

A classificação regular/irregular é operacional e baseada na geometria da Fronteira de Pareto. Fronteiras regulares são contínuas, suaves e relativamente bem distribuídas, como ocorre em DTLZ1–DTLZ4. Fronteiras irregulares apresentam degenerescência, descontinuidade, enviesamento, regiões desconectadas, não uniformidade ou inversão geométrica que prejudicam a correspondência entre vetores de peso e soluções bem distribuídas. Neste artigo, DTLZ5–DTLZ7 e IDTLZ1–IDTLZ2 são tratados como instâncias irregulares [Deb et al. 2005, Tian et al. 2017].

É importante delimitar o escopo de validade dos resultados. Como a escalarização de Tchebycheff foi mantida fixa em todos os experimentos, os achados refletem a interação entre operador de reprodução e essa escalarização específica, não uma propriedade geral do MOEA/D. Outras escalarizações como PBI e soma ponderada, podem alterar a magnitude ou até o sinal de algumas comparações, especialmente em frentes irregulares, em que a escolha da função de agregação afeta fortemente a distribuição de soluções [Zhang and Li 2007, Li and Zhang 2009]. Este artigo não avalia essa interação, trata-se de uma limitação assumida e uma direção explícita de trabalho futuro (Seção 6).

4. Metodologia Experimental

Os experimentos foram conduzidos em MATLAB R2026a com PlatEMO 4.15, release de maio de 2026 [Tian et al. 2017, BIMK Group 2026]. O ambiente computacional utilizou processador 13th Gen Intel(R) Core(TM) i7-1360P, 2.20 GHz, 16 GB de RAM, sistema operacional de 64 bits e arquitetura x64. Dados identificáveis e desnecessários foram omitidos. Os scripts, a plataforma customizada e os resultados brutos das 30 execuções por configuração estão disponíveis publicamente como artefato do estudo¹.

O protocolo considerou instâncias DTLZ e IDTLZ com $M \in \{2, 3, 4, 5\}$ objetivos e as configurações de dimensionalidade e orçamento computacional detalhadas na Tabela 1. Para $M = 2-4$, o orçamento de avaliações foi $maxFE = 120.000$; para $M = 5$, $maxFE = 126.000$, com tamanho de população $N = 120$ ($M = 2-4$) e $N = 126$ ($M = 5$), seguindo a convenção de vetores de peso gerados por `UniformPoint`. Cenários com $D = 100$ representam a condição de alta dimensionalidade decisória para os problemas onde essa configuração é aplicável. Cada configuração foi executada 30 vezes de forma independente. A Tabela 1 resume o protocolo.

Tabela 1. Configuração experimental.

Componente	Descrição
Algoritmo base	MOEA/D com escalarização de Tchebycheff.
Operadores	ABC, ACO, CMA-ES, DE, EDA, MMOPSO, NMS e SA como variantes de reprodução acopladas ao MOEA/D.
Benchmarks	DTLZ1–DTLZ4 (fronteiras regulares); DTLZ5–DTLZ7 e IDTLZ1–IDTLZ2 (fronteiras irregulares).
Objetivos e dimensão	$M \in \{2, 3, 4, 5\}$; configurações padrão e $D = 100$ quando aplicável.
Execuções	30 execuções independentes por configuração.
Métrica	IGD, com menor valor indicando melhor desempenho.
Comparação estatística	Teste de Wilcoxon contra o MOEA/D base, com $\alpha = 0,05$.
População e vizinhança	$N = 120$ ($M = 2-4$); $N = 126$ ($M = 5$); $T = \lceil N/10 \rceil$.
Vetores de peso	Gerados por <code>UniformPoint</code> na implementação do MOEA/D.
Critério de parada	$maxFE = 120.000$ ($M = 2-4$); $maxFE = 126.000$ ($M = 5$).
Ambiente	MATLAB R2026a; PlatEMO 4.15; Intel Core i7-1360P 2.20 GHz; 16 GB RAM; sistema operacional de 64 bits; arquitetura x64.

Para cada operador, os resultados foram comparados ao MOEA/D base por meio do teste de Wilcoxon pareado por configuração experimental. Os símbolos +, – e $\approx$ indicam, respectivamente, desempenho estatisticamente superior, inferior ou equivalente ao MOEA/D base. Como o estudo envolve múltiplas comparações entre operadores, instâncias e cenários, os valores de p devem ser reportados nos artefatos completos e, quando disponíveis, submetidos a correção por Holm ou FDR [Wilcoxon 1945, Holm 1979, Benjamini and Hochberg 1995]. Nesta versão, os valores individuais de p não estavam disponíveis; por isso, os sinais estatísticos originais foram preservados sem reclassificação por correção múltipla.

Durante a curadoria das tabelas originais, foram identificadas repetições exatas em parte dos resultados de problemas irregulares. Para evitar contagem duplicada, a

¹<https://github.com/belamedeirosbl/PlatEMO-moead-variation-strategies>

agregação da Seção 5 considera apenas combinações únicas de problema, número de objetivos e dimensionalidade. Essa mesma curadoria foi aplicada às tabelas detalhadas de IGD, de modo que os resultados completos apresentados nas Tabelas 4 e 5 documentam as configurações únicas usadas na análise agregada.

5. Resultados e Discussão

A Tabela 2 é a tabela principal de síntese dos resultados, enquanto as Tabelas 4 e 5 apresentam os valores detalhados de IGD por configuração experimental. Cada célula da Tabela 2 mostra os contadores de vitória, derrota e empate estatístico (+ / - / $\approx$) em relação ao MOEA/D base e, entre parênteses, a razão geométrica $r = \text{IGD}_{op}/\text{IGD}_{base}$, onde IGD_{op} é o IGD médio obtido pela variante com o respectivo operador de reprodução, e IGD_{base} é o IGD médio obtido pelo MOEA/D base.

Tabela 2. Resultados agregados por cenário. Cada célula mostra + / - / $\approx$ e, entre parênteses, r , a média geométrica de $\text{IGD}_{op}/\text{IGD}_{base}$ nas configurações únicas do grupo.

Grupo	ABC	ACO	CMA-ES	DE	EDA	MMOPSO	NMS	SA
Regulares, 2–3 obj.	6/8/2 (1.30)	2/11/3 (4.20)	1/15/0 (2.79)	3/7/6 (1.02)	3/11/2 (4.57)	4/6/6 (0.99)	1/12/3 (10.20)	5/9/2 (1.17)
Regulares, 4–5 obj.	9/4/3 (0.90)	2/9/5 (8.68)	1/14/1 (4.48)	6/7/3 (1.23)	3/11/2 (12.50)	6/8/2 (1.06)	0/16/0 (10.50)	9/4/3 (0.90)
Irregulares, 2–3 obj.	1/9/2 (2.03)	2/10/0 (4.08)	0/11/1 (9.58)	2/7/3 (1.69)	2/10/0 (8.15)	2/9/1 (0.95)	0/12/0 (6.29)	1/8/3 (2.06)
Irregulares, 4–5 obj.	2/8/2 (0.64)	3/8/1 (3.48)	2/10/0 (4.24)	2/8/2 (0.90)	4/8/0 (9.32)	4/6/2 (0.64)	0/12/0 (6.13)	2/7/3 (0.65)

Nos problemas regulares com poucos objetivos, ABC obteve seis vitórias, seguido por SA com cinco, enquanto MMOPSO e DE obtiveram quatro e três vitórias, respectivamente. O valor agregado de IGD favorece levemente MMOPSO ($r = 0,99$), ao passo que DE permanece próximo do MOEA/D base ($r = 1,02$). Como todos acumulam perdas, esse cenário não sustenta a recomendação de um substituto direto universal. Em problemas regulares com quatro e cinco objetivos, ABC e SA apresentam o melhor perfil agregado, ambos com nove vitórias, quatro derrotas e três empates, além de $r = 0,90$. Esse é o achado mais forte do estudo: em frentes regulares com muitos objetivos, operadores com diversificação estocástica parecem preservar melhor cobertura sem romper a estrutura de decomposição.

Nos problemas irregulares, a leitura deve ser mais cautelosa. Com dois e três objetivos, DE apresenta o melhor balanço relativo entre vitórias, derrotas e empates, embora tenha apenas duas vitórias em doze configurações únicas. MMOPSO exibe a menor razão agregada de IGD ($r = 0,95$), mas com nove derrotas estatísticas, o que caracteriza ganho localizado. Com quatro e cinco objetivos, MMOPSO apresenta o melhor perfil agregado, com quatro vitórias, seis derrotas e dois empates, além de $r = 0,64$. ABC e SA também têm razões agregadas favoráveis nesse grupo, mas com poucas vitórias estatísticas. Assim, razões de IGD e sinais estatísticos devem ser lidos em conjunto.

O comportamento dos operadores sugere explicações plausíveis, mas não definitivas, sendo útil compará-lo ao que a literatura de seleção adaptativa já reporta. DE pode explorar direções úteis quando diferenças vetoriais refletem a estrutura local da população, condição comum em frentes regulares simples, mas perde eficiência quando frentes irregulares distorcem a relação entre vizinhança de pesos e regiões promissoras. Esse padrão é coerente com a motivação original de Li e Zhang [Li and Zhang 2009] para combinar DE com mecanismos de reparo em *Pareto sets* complicados. MMOPSO pode alcançar

regiões difíceis por trajetórias coletivas via *pbest/gbest*, porém sua vantagem é instável (poucas vitórias estatísticas apesar de razões de IGD favoráveis). Esse resultado ecoa a observação de Lin et al. [Lin et al. 2015] de que estratégias múltiplas de busca ajudam na cobertura, mas nem sempre garantem convergência estatisticamente superior. ABC e SA parecem mais favoráveis em frentes regulares com muitos objetivos, possivelmente por combinarem diversificação e perturbações menos dependentes de modelos globais e da covariância estimada da população. Isso também ajuda a explicar por que CMA-ES e EDA podem sofrer em espaços maiores, onde suas estimativas de distribuição se tornam ruidosas com poucas amostras por vizinhança. Esse comportamento é consistente com trabalhos de seleção adaptativa via *bandits* [Li et al. 2014, Almeida et al. 2018], que reportam desempenho não uniforme de operadores baseados em modelo probabilístico quando a vizinhança de amostragem é pequena. NMS quase sempre perde, o que é compatível com a limitação de uma busca local simplex — isolada do componente DE da proposta original de Zhang et al. [Zhang et al. 2017] — quando o MOEA/D precisa manter diversidade distribuída entre subproblemas.

Tabela 3. Síntese prática das evidências observadas. As recomendações são condicionais e não indicam superioridade universal.

Cenário	Operadores mais pro-missores	Interpretação
Fronteiras regulares, 2–3 objetivos	ABC, SA e MMOPSO	Ganhos possíveis, mas sensíveis ao aumento de dimensão e sem dominância clara; recomenda-se validação por instância.
Fronteiras regulares, 4–5 objetivos	ABC e SA	Melhor perfil agregado; bons candidatos iniciais para análise de sensibilidade.
Fronteiras irregulares, 2–3 objetivos	DE e MMOPSO, com cautela	Ganhos localizados; sinais estatísticos e razão de IGD não apontam domínio amplo.
Fronteiras irregulares, 4–5 objetivos	MMOPSO, com cautela	Melhor balanço agregado, mas ainda com derrotas suficientes para evitar conclusão universal.
Alta dimensionalidade	Evitar NMS como substituto direto	Busca local simples tende a prejudicar diversidade e cobertura no MOEA/D.

Os achados fortes são a ausência de operador universal, o bom desempenho relativo de ABC e SA em frentes regulares com muitos objetivos e a fragilidade recorrente de NMS. Os achados localizados incluem ganhos de DE em alguns problemas irregulares com poucos objetivos e ganhos de MMOPSO em problemas irregulares com muitos objetivos. Essa distinção evita superinterpretação e preserva a mensagem principal: a escolha do operador deve ser condicionada ao cenário.

5.1. Resultados detalhados por configuração

A Tabela 2 resume os resultados por grupo de problema, operador e cenário experimental. Para tornar a análise auditável no próprio manuscrito, as Tabelas 4 e 5 apresentam os valores detalhados de IGD usados na agregação, consolidando em uma única tabela os objetivos $M = 2-5$ e as dimensionalidades avaliadas. A Tabela 4 reporta os problemas com Fronteira de Pareto regular; a Tabela 5 apresenta os problemas com Fronteira de Pareto irregular, considerando apenas configurações únicas. Em ambas, cada célula mostra a média de IGD e o sinal estatístico em relação ao MOEA/D base (+: melhor; -: pior; $\approx$: equivalente); os desvios padrão completos estão disponíveis nos artefatos do estudo. Assim, a Tabela 2 funciona como síntese interpretativa, enquanto as Tabelas 4 e 5 preservam a rastreabilidade dos resultados por configuração.

6. Conclusão

Este artigo apresentou um estudo empírico controlado sobre a sensibilidade do MOEA/D a operadores de reprodução sob decomposição de Tchebycheff. A questão de pesquisa foi respondida afirmativamente: a escolha do operador altera o desempenho do MOEA/D, mas esse efeito depende da geometria da Fronteira de Pareto, do número de objetivos e da dimensionalidade.

Os resultados não sustentam a existência de um operador universalmente superior. ABC e SA foram mais competitivos em frentes regulares com muitos objetivos; DE e MMOPSO apresentaram ganhos localizados em frentes irregulares; e NMS mostrou desempenho desfavorável na maior parte das comparações. Como implicação prática, recomenda-se tratar operadores de reprodução como escolhas condicionadas ao cenário, e não como substitutos globais do operador padrão do MOEA/D.

Esses achados motivam seleção adaptativa de operadores. Uma extensão natural é alternar operadores durante a execução com base em sinais da busca, como dispersão das soluções, progresso da IGD, dificuldade dos subproblemas e estimativas da geometria da fronteira. Trabalhos futuros também devem comparar Tchebycheff com PBI e soma ponderada, reportar Hipervolume, aplicar Holm ou FDR quando os valores de p estiverem disponíveis, avaliar WFG e incluir problemas reais de engenharia.

Referências

- Almeida, C. P., Gonçalves, R. A., Venske, S., Lüders, R., and Delgado, M. (2018). Hyperheuristics using multi-armed bandit models for multi-objective optimization. *Swarm and Evolutionary Computation*, 42:15–27.
- Benjamini, Y. and Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1):289–300.
- BIMK Group (2026). PlatEMO release notes: Release highlights of PlatEMO 4.15. <https://github.com/BIMK/PlatEMO/blob/master/Doc/releasenote.md>. Accessed in 2026.
- Deb, K., Thiele, L., Laumanns, M., and Zitzler, E. (2005). Scalable test problems for evolutionary multiobjective optimization. In *Evolutionary Multiobjective Optimization: Theoretical Advances and Applications*, pages 105–145. Springer.

Tabela 4. Resultados de IGD para problemas com Fronteira de Pareto regular ($M = 2-5$; D padrão e $D = 100$). Cada célula mostra a média de IGD e o sinal estatístico em relação ao MOEA/D base (+: melhor; -: pior; $\approx$: equivalente); células sombreadas indicam o menor IGD médio da linha, incluindo o MOEA/D base, com desempenhos decididos por casas decimais não exibidas; desvios padrão completos estão disponíveis nos artefatos do estudo.

Prob.	M	D	ABC	ACO	CMA-ES	DE	EDA	MMOPSO	NMS	SA	Base
DTLZ1	2	6	1.49e-3 $\approx$	3.69e-2	3.68e-3	1.49e-3 $\approx$	5.33e-2	1.49e-3 $\approx$	7.61e+0	1.49e-3 $\approx$	1.49e-3
	3	7	2.61e-2 +	2.63e+0	1.02e-1	2.60e-2 +	1.16e+1	2.62e-2 +	1.60e+1	2.62e-2 +	2.63e-2
	2	100	1.84e+2	2.35e+2	5.95e+1	3.60e+2	4.25e+2	2.21e+2	8.15e+2	1.90e+2	3.77e+1
	3	100	1.70e+2	2.14e+3	1.56e+3	1.06e+2 $\approx$	1.77e+3	2.74e+2	7.09e+2	1.74e+2	9.50e+1
	4	8	8.99e-2 +	7.33e+0	2.19e-1 $\approx$	9.85e-2	1.40e+1	1.05e-1	1.52e+1	9.00e-2 +	9.02e-2
	5	9	1.14e-1 $\approx$	8.71e+0	3.82e-1	1.86e-1	1.59e+1	1.55e-1	1.59e+1	1.14e-1 $\approx$	1.13e-1
	4	100	1.08e+2	2.05e+3	1.65e+3	5.30e+1 +	1.66e+3	2.47e+2	7.84e+2	1.07e+2	6.51e+1
	5	100	7.52e+1 $\approx$	1.89e+3	1.73e+3	9.01e+1 $\approx$	1.55e+3	1.20e+2	8.41e+2	8.15e+1 $\approx$	7.74e+1
	2	11	3.30e-3	3.30e-3	3.36e-3	3.30e-3	3.31e-3	3.30e-3	3.45e-3	3.30e-3	3.30e-3
	3	12	6.40e-2 +	6.38e-2 +	6.12e-2 +	6.38e-2 +	6.37e-2 +	6.36e-2 +	9.87e-2	6.40e-2 +	6.44e-2
DTLZ2	2	100	4.81e-3	3.49e-3	1.74e-2	5.84e-3	7.45e-3	3.69e-3	1.45e-2	4.76e-3	3.32e-3
	3	100	6.53e-2	6.46e-2	1.19e-1	9.63e-2	1.59e-1	6.39e-2 +	4.35e-1	6.51e-2	6.43e-2
	4	13	2.38e-1 +	2.35e-1 +	1.84e-1 +	2.36e-1 +	2.35e-1 +	2.33e-1 +	3.39e-1	2.38e-1 +	2.39e-1
	5	14	3.21e-1 +	3.18e-1 +	4.18e-1	3.22e-1	3.21e-1 +	3.21e-1 $\approx$	5.85e-1	3.21e-1 +	3.21e-1
	4	100	2.37e-1 $\approx$	2.38e-1 $\approx$	3.07e-1	2.60e-1	2.43e+0	2.34e-1 +	7.63e-1	2.37e-1 $\approx$	2.38e-1
	5	100	3.28e-1	3.63e-1	5.25e-1	5.38e-1	4.57e+0	3.30e-1	9.65e-1	3.29e-1	3.22e-1
	2	11	3.67e-3	5.81e+0	2.25e-1	5.10e-3	1.65e+1	3.55e-3 $\approx$	1.64e+2	3.64e-3	3.45e-3
	3	12	6.38e-2 +	4.59e+1	4.80e+0	6.52e-2	1.21e+2	6.40e-2 $\approx$	1.81e+2	6.37e-2 +	6.42e-2
	2	100	4.18e+2	5.30e+2	1.82e+2	6.51e+2	9.38e+2	3.67e+2	2.22e+3	4.20e+2	8.82e+1
	3	100	3.75e+2	4.57e+3	2.46e+3	2.82e+2 $\approx$	4.13e+3	3.80e+2	2.06e+3	3.65e+2	1.49e+2
DTLZ3	4	13	2.36e-1 +	1.41e+2	5.34e+0	2.60e+0	1.64e+2	2.49e-1	1.87e+2	2.35e-1 +	2.37e-1
	5	14	3.57e-1	1.85e+2	7.43e+0	1.47e+0	1.73e+2	3.93e-1	1.77e+2	3.49e-1	3.21e-1
	4	100	2.10e+2	6.97e+3	6.02e+3	1.98e+2 $\approx$	5.43e+3	2.89e+2	2.20e+3	2.23e+2	1.81e+2
	5	100	1.47e+2 +	7.07e+3	6.24e+3	2.08e+2 +	5.48e+3	1.86e+2 +	2.09e+3	1.31e+2 +	2.51e+2
	2	11	2.00e-1 +	1.26e-1 +	4.47e-1	2.80e-2 +	2.79e-2 +	7.72e-2 +	3.58e-3 +	2.99e-1	2.25e-1
	3	12	2.40e-1 +	1.98e-1 $\approx$	7.25e-1	1.16e-1 $\approx$	1.61e-1 $\approx$	9.61e-2 $\approx$	3.26e-1 $\approx$	1.82e-1 +	3.25e-1
	2	100	4.23e-1 +	2.00e-1 $\approx$	7.18e-1	1.80e-1 $\approx$	9.33e-3 $\approx$	3.98e-1 $\approx$	8.79e-3 $\approx$	3.73e-1 +	4.47e-1
	3	100	4.54e-1 $\approx$	3.96e-1 $\approx$	9.25e-1	3.88e-1 $\approx$	1.90e-1 +	3.30e-1 $\approx$	4.64e-1 $\approx$	2.96e-1 $\approx$	6.21e-1
	4	13	2.63e-1 +	3.81e-1 $\approx$	7.77e-1	2.81e-1 $\approx$	2.94e-1 $\approx$	3.01e-1 $\approx$	5.74e-1	2.91e-1 +	4.37e-1
	5	14	3.25e-1 +	4.96e-1 $\approx$	8.28e-1	3.61e-1 +	3.77e-1 +	3.42e-1 +	8.55e-1	3.25e-1 +	5.29e-1
DTLZ4	4	100	4.02e-1 +	5.13e-1 $\approx$	9.68e-1	4.18e-1 +	6.70e-1 $\approx$	4.53e-1 +	8.63e-1	3.77e-1 +	6.72e-1
	5	100	4.88e-1 +	5.97e-1 $\approx$	1.09e+0	5.06e-1 +	1.39e+0	4.48e-1 +	1.64e+0	4.57e-1 +	7.05e-1
+ / - / $\approx$			15/12/5	4/20/8	2/29/1	9/14/9	6/22/4	10/14/8	1/28/3	14/13/5	

- Dorigo, M., Maniezzo, V., and Colorni, A. (1996). Ant system: optimization by a colony of cooperating agents. *IEEE Transactions on Systems, Man, and Cybernetics, Part B*, 26(1):29–41.
- Hansen, N. and Ostermeier, A. (2001). Completely derandomized self-adaptation in evolution strategies. *Evolutionary Computation*, 9(2):159–195.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70.
- Karaboga, D. and Basturk, B. (2007). A powerful and efficient algorithm for numerical function optimization: artificial bee colony (ABC) algorithm. *Journal of Global Optimization*, 39(3):459–471.
- Ke, L., Zhang, Q., and Battiti, R. (2013). MOEA/D-ACO: A multiobjective evolutionary algorithm using decomposition and ant colony. *IEEE Transactions on Cybernetics*, 43(6):1845–1859.
- Kirkpatrick, S., Gelatt, C. D., and Vecchi, M. P. (1983). Optimization by simulated annealing. *Science*, 220(4598):671–680.
- Li, H. and Landa-Silva, D. (2011). An adaptive evolutionary multi-objective approach based on simulated annealing. *Evolutionary Computation*, 19(4):561–595.
- Li, H. and Zhang, Q. (2009). Multiobjective optimization problems with complicated Pareto sets, MOEA/D and NSGA-II. *IEEE Transactions on Evolutionary Computation*, 13(2):284–302.
- Li, K. (2024). A survey of multi-objective evolutionary algorithm based on decomposition: Past and future. *IEEE Transactions on Evolutionary Computation*, pages 1–1.
- Li, K., Fialho, Á., Kwong, S., and Zhang, Q. (2014). Adaptive operator selection with bandits for a multiobjective evolutionary algorithm based on decomposition. *IEEE Transactions on Evolutionary Computation*, 18(1):114–130.
- Lin, Q., Li, J., Du, Z., Chen, J., and Ming, Z. (2015). A novel multi-objective particle swarm optimization with multiple search strategies. *European Journal of Operational Research*, 247(3):732–744.
- Nelder, J. A. and Mead, R. (1965). A simplex method for function minimization. *The Computer Journal*, 7(4):308–313.
- Storn, R. and Price, K. (1997). Differential evolution: A simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11(4):341–359.
- Tian, Y., Cheng, R., Zhang, X., and Jin, Y. (2017). PlatEMO: A MATLAB platform for evolutionary multi-objective optimization. *IEEE Computational Intelligence Magazine*, 12(4):73–87.
- Van Veldhuizen, D. A. and Lamont, G. B. (1998). Evolutionary computation and convergence to a Pareto front. In *Late Breaking Papers at the Genetic Programming 1998 Conference*, pages 221–228.

- Wang, R., Zhang, Q., and Zhang, T. (2015). Pareto adaptive scalarising functions for decomposition based algorithms. In *Evolutionary Multi-Criterion Optimization*, pages 248–262.
- Wang, W., Yang, S., Lin, Q., Coello, C. A. C., Zhang, Q., Wong, K.-S., and Chen, J. (2019). An effective ensemble framework for multiobjective optimization. *IEEE Transactions on Cybernetics*, 49(3):1120–1133.
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83.
- Zapotecas-Martínez, S., Derbel, B., Liefooghe, A., Brockhoff, D., Aguirre, H. E., and Tanaka, K. (2015). Injecting CMA-ES into MOEA/D. In *Proceedings of the Genetic and Evolutionary Computation Conference*, pages 783–790.
- Zhang, H., Zhou, A., Zhang, G., and Singh, H. K. (2017). Accelerating MOEA/D by Nelder-Mead method. In *2017 IEEE Congress on Evolutionary Computation (CEC)*, pages 976–983.
- Zhang, Q. and Li, H. (2007). MOEA/D: A multiobjective evolutionary algorithm based on decomposition. *IEEE Transactions on Evolutionary Computation*, 11(6).
- Zhong, Y. B., Xiang, Y., and Liu, H. L. (2014). A multi-objective artificial bee colony algorithm based on division of the searching space. *Applied Intelligence*, 41(4):987–1011.
- Zhou, A., Gao, F., and Zhang, G. (2015). A decomposition based estimation of distribution algorithm for multiobjective traveling salesman problems. *Computers & Mathematics with Applications*, 70(12):3132–3149.